

Estadística Inferencial

CM2H2

REGRESION LINEAL

FC-UNI

23 de junio de 2026

Motivación: ¿Por qué Regresión?

En ciencia e ingeniería, a menudo queremos entender cómo una variable Y (dependiente) cambia en función de otra variable X (independiente).

- ▶ ¿Cómo varía los ingresos y gastos familiares?
- ▶ ¿Cuál es la relación entre el gasto en publicidad y las ventas?
- ▶ ¿Cómo influye la presión en la solubilidad de un gas?

La **Regresión Lineal** es la herramienta estadística básica para modelar estas relaciones.

El Modelo Estadístico Lineal

Supongamos que se tienen los siguientes datos para las variables x, y :

x	x_1	x_2	$\cdots$	x_n
y	y_1	y_2	$\cdots$	y_n

Y que la relación poblacional es de la forma:

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

Donde:

- ▶ β_0 : Intercepto (valor de Y cuando $x = 0$).
- ▶ β_1 : Pendiente (cambio en Y por unidad de cambio en x).
- ▶ ϵ_i : Error aleatorio o perturbación.

Supuestos básicos: $\epsilon_i \sim N(0, \sigma^2)$, independientes y con varianza constante.

El Criterio de Mínimos Cuadrados

Buscamos los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la Suma de Cuadrados del Error (SCE):

$$\text{SCE} = S(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Estimadores MCO

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Se requiere que:

$$\begin{aligned}\mathbf{SCE} = S(\hat{\beta}_0, \hat{\beta}_1) &= \sum_{i=1}^n (y_i - \hat{y}_1)^2 \\ &= \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2\end{aligned}$$

sea lo más pequeña posible para que la recta $y = \beta_1 x + \beta_0$ sea la que mejor representa el comportamiento lineal de los puntos (x_i, y_i) .

Consideremos la función f de las variables m y b dada por:

$$S(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Buscamos sus puntos críticos



$$\frac{\partial S}{\partial \hat{\beta}_1} = 2 \sum_{i=1}^n x_i (y_i - (\hat{\beta}_1 x_i + \hat{\beta}_0)) = 0$$



$$\frac{\partial f}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - (\hat{\beta}_1 x_i + \hat{\beta}_0)) = 0$$

Obtención del parámetro b

De la segunda ecuación obtenemos:

$$\sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i - \sum_{i=1}^n \hat{\beta}_0 = 0$$

De donde:

$$\hat{\beta}_0 = \frac{1}{n} \sum_{i=1}^n y_i - \hat{\beta}_1 \left(\frac{1}{n} \sum_{i=1}^n x_i \right)$$

Si:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

que son las medias aritméticas. Entonces:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Obtención del parámetro $\hat{\beta}_1$

Sustituyendo $\hat{\beta}_0$ en la primera ecuación $\frac{\partial S}{\partial \hat{\beta}_1} = 0$:

$$\sum_{i=1}^n x_i(y_i - \hat{\beta}_1 x_i - (\bar{y} - \hat{\beta}_1 \bar{x})) = 0$$

Resolviendo para $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i(y_i - \bar{y})}{\sum_{i=1}^n x_i(x_i - \bar{x})} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Verificación del Mínimo Local

Recurrimos al criterio de la segunda derivada:

$$\frac{\partial^2 \mathcal{S}}{\partial \hat{\beta}_1^2} = 2 \sum_{i=1}^n x_i^2, \quad \frac{\partial^2 \mathcal{S}}{\partial \hat{\beta}_1 \partial \hat{\beta}_0} = 2 \sum_{i=1}^n x_i, \quad \frac{\partial^2 \mathcal{S}}{\partial \hat{\beta}_0^2} = 2n$$

Tenemos que $\frac{\partial^2 \mathcal{S}}{\partial \hat{\beta}_1^2} > 0$. Por otro lado, evaluando el determinante del Hessiano:

$$\left(2 \sum_{i=1}^n x_i \right)^2 - \left(2 \sum_{i=1}^n x_i^2 \right) (2n) < 0$$

Luego, se tiene mínimo en el punto $(\hat{\beta}_0, \hat{\beta}_1)$

Propiedades de los Estimadores

los estimadores $\hat{\beta}_i$ son:

- ▶ **Insesgados:** $E(\hat{\beta}_i) = \beta_i$.
- ▶ **Eficientes:** Tienen la varianza mínima entre los estimadores lineales.
- ▶ Un estimador insesgado de σ^2 es $S^2 = \text{SSE}/(n - 2)$, donde $\text{SSE} = S_{yy} - \hat{\beta}_1 S_{xy}$ y $S_{yy} = \sum (y_i - \bar{y})^2$.
- ▶ La varianza del error σ^2 se estima mediante el Error Cuadrático Medio:

$$\hat{\sigma}^2 = S^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n - 2} = \frac{\text{SCE}}{n - 2}$$

Propiedades de los estimadores de mínimos cuadrados

Más propiedades de los estimadores de mínimos cuadrados; regresión lineal simple

1. $V(\hat{\beta}_0) = c_{00}\sigma^2$, donde $c_{00} = \sum x_i^2 / (nS_{xx})$.

2. $V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$.

3. $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \frac{-\bar{x}}{S_{xx}}\sigma^2$.

Si, además, el ε_i , para $i = 1, 2, \dots, n$ está distribuido normalmente,

4. $\hat{\beta}_0$ y $\hat{\beta}_1$ están distribuidas normalmente.

5. La variable aleatoria $\frac{(n-2)S^2}{\sigma^2}$ tiene una distribución χ^2 con $n-2$ grados de libertad.

6. El estadístico S^2 es independiente de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Coefficiente de correlación

Coefficiente de Correlación de Pearson (r): mide la fuerza y dirección de la relación lineal. $-1 \leq r \leq 1$.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right] \left[\sum_{i=1}^n (y_i - \bar{y})^2 \right]}} = \frac{S_{XY}}{\sqrt{S_{XX} \cdot S_{YY}}}$$

o también:
$$r = \frac{n \sum_{i=1}^n (x_i y_i) - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sqrt{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} \sqrt{n \sum_{i=1}^n y_i^2 - \left(\sum_{i=1}^n y_i \right)^2}}.$$

Ejemplo: Publicidad vs Ventas

En un estudio de la relación entre la publicidad por radio (X) y las ventas de un producto (Y), se recopilaron datos durante 10 semanas:

Semana	1	2	3	4	5	6	7	8	9	10
Publicidad X	20	30	30	40	50	60	60	60	70	80
Ventas Y	50	73	69	87	108	128	135	132	148	170

- Trazar el diagrama de dispersión e indicar la tendencia.
- Calcular la recta de regresión de mínimos cuadrados.
- Estimar la venta si se hacen 100 minutos de propaganda.
- Calcular el coeficiente de correlación.
- Si en la novena semana se incrementara la publicidad en 5 min, ¿en cuánto se estima el incremento de ventas?

b) Cálculo de los Coeficientes (Cómputo)

Para obtener la recta $y = \beta_0 + \beta_1 x$, calculamos las sumatorias necesarias:

x	y	xy	x^2	y^2
20	50	1000	400	2500
30	73	2190	900	5329
30	69	2070	900	4761
40	87	3480	1600	7569
50	108	5400	2500	11664
60	128	7680	3600	16384
60	135	8100	3600	18225
60	132	7920	3600	17424
70	148	10360	4900	21904
80	170	13600	6400	28900
500	1100	61800	28400	134660

$$\text{Medias: } \bar{x} = \frac{500}{10} = 50, \quad \bar{y} = \frac{1100}{10} = 110.$$

b) Obtención de la Recta de Regresión

Cálculo de la pendiente β_1


$$\beta_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{10(61800) - (500)(1100)}{10(28400) - (500)^2}$$
$$\beta_1 = \frac{68000}{34000} = 2$$

Cálculo de la intercepción β_0

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = 110 - 2(50) = 10$$

Recta estimada: $\hat{y} = 10 + 2x$

a) Diagrama de Dispersión y Tendencia



Tendencia: Lineal positiva fuerte.

c), d) y e) Resolución

c) Para $x = 100$ **min**:

$$\hat{y} = 10 + 2(100) = \mathbf{210} \text{ artículos.}$$

d) *Coeficiente de Correlación (r)*: Usando la fórmula

$$r = \frac{s_{XY}}{\sqrt{s_{XX}s_{YY}}}$$

$$r = \frac{680}{\sqrt{340 \times 1366}} \approx \mathbf{0,998}$$

Indica una relación lineal casi perfecta.

e) **Incremento en publicidad de 5 min**: Recordemos que $\beta_0 = 2$ representa el incremento en y por cada unidad de x .

$$\Delta \hat{y} = \cdot \Delta x = 2 \cdot (5) = 10 \text{ ventas adicionales.}$$

Ejemplo Ajuste de Recta

Ajustar una recta a los $n = 5$ puntos de la tabla.

Cuadro: Datos e iteraciones

x_i	y_i	$x_i y_i$	x_i^2
-2	0	0	4
-1	0	0	1
0	1	0	0
1	1	1	1
2	3	6	4
0	5	7	10

Ejemplo Ajuste de Recta

Ajustar una recta a los $n = 5$ puntos de la tabla.

Cuadro: Datos e iteraciones

x_i	y_i	$x_i y_i$	x_i^2
-2	0	0	4
-1	0	0	1
0	1	0	0
1	1	1	1
2	3	6	4
0	5	7	10

Cálculos preliminares:

- ▶ $n = 5$
- ▶ $\bar{x} = \frac{0}{5} = 0$
- ▶ $\bar{y} = \frac{5}{5} = 1$
- ▶ $S_{xx} = \sum x_i^2 - \frac{1}{n}(\sum x_i)^2 = 10$
- ▶ $S_{xy} = \sum x_i y_i - \frac{1}{n}(\sum x_i)(\sum y_i) = 7$

Ejemplo: Solución

Calculamos la pendiente ($\hat{\beta}_1$) y la intersección ($\hat{\beta}_0$):

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{7 - \frac{1}{5}(0)(5)}{10 - \frac{1}{5}(0)^2} = \frac{7}{10} = 0,7$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \frac{5}{5} - (0,7)(0) = 1$$

Ejemplo: Solución

Calculamos la pendiente ($\hat{\beta}_1$) y la intersección ($\hat{\beta}_0$):


$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{7 - \frac{1}{5}(0)(5)}{10 - \frac{1}{5}(0)^2} = \frac{7}{10} = 0,7$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \frac{5}{5} - (0,7)(0) = 1$$

Recta:

$$\hat{y} = 1 + 0,7x$$

Ejemplo: Gráfico



Ejemplo: Varianzas de los Estimadores

Encuentre las varianzas de $\hat{\beta}_0$ y $\hat{\beta}_1$ para los datos anteriores. Dado que $n = 5$, $\sum x_i = 0$, $\sum x_i^2 = 10$, $S_{xx} = 10$ y $\bar{x} = 0$:

De $\hat{\beta}_0$:

$$V(\hat{\beta}_0) = \frac{\sigma^2 \sum x_i^2}{n S_{xx}} = \frac{\sigma^2(10)}{5(10)} = \left(\frac{1}{5}\right) \sigma^2$$

De $\hat{\beta}_1$:

$$V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} = \left(\frac{1}{10}\right) \sigma^2$$

Covarianza:

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = 0 \quad \text{porque} \quad \sum x_i = 0$$

Ejemplo: Estimación de σ^2

Calcule s^2 con los datos del Ejemplo 11.1. Sabemos que $\sum y_i = 5$, $S_{xy} = 7$, $\hat{\beta}_1 = 0,7$ y $\sum y_i^2 = 11$.

Ejemplo: Estimación de σ^2

Calcule s^2 con los datos del Ejemplo 11.1. Sabemos que $\sum y_i = 5$, $S_{xy} = 7$, $\hat{\beta}_1 = 0,7$ y $\sum y_i^2 = 11$.

1. S_{yy} :

$$S_{yy} = \sum y_i^2 - n(\bar{y})^2 = 11 - 5(1)^2 = 6,0$$

2. **Suma de Cuadrados del Error (SSE):**

$$SSE = S_{yy} - \hat{\beta}_1 S_{xy} = 6,0 - (0,7)(7) = 1,1$$

3. **Varianza muestral s^2 :**

$$s^2 = \frac{SSE}{n-2} = \frac{1,1}{5-2} = \frac{1,1}{3} \approx 0,367$$

Para verificar si existe una relación lineal significativa, probamos:

$$H_0 : \beta_1 = 0 \text{ vs } H_a : \beta_1 \neq 0$$

Estadístico de Prueba

$$T = \frac{\hat{\beta}_1 - 0}{S/\sqrt{S_{xx}}} \sim t_{n-2}$$

Si rechazamos H_0 , concluimos que x ayuda significativamente a explicar la variabilidad de Y .

Ejemplo: Prueba de Hipótesis para la Pendiente

Pregunta: ¿Presentan los datos evidencia suficiente para indicar que la pendiente difiere de 0? ($\alpha = 0,05$)

Planteamiento:

- ▶ Hipótesis Nula (H_0): $\beta_1 = 0$ (No hay relación lineal)
- ▶ Hipótesis Alternativa (H_a): $\beta_1 \neq 0$ (Existe relación lineal)

Datos previos necesarios:

- ▶ $\hat{\beta}_1 = 0,7$
- ▶ $S_{xx} = 10$
- ▶ $c_{11} = 1/S_{xx} = 0,1$
- ▶ $s^2 = 0,367$
- ▶ $s = \sqrt{0,367} = 0,606$
- ▶ g.l. = $n - 2 = 3$

Ejemplo: Estadístico de Prueba

Calculamos el valor de la estadística t para la pendiente:

$$t = \frac{\hat{\beta}_1 - 0}{s\sqrt{c_{11}}} = \frac{0,7 - 0}{0,606\sqrt{0,1}} = \frac{0,7}{0,1916} = 3,65$$

Regla de Decisión ($\alpha = 0,05$):

- ▶ Para 3 grados de libertad, el valor crítico es $t_{\alpha/2} = t_{0,025} = 3,182$.
- ▶ Región de rechazo: Rechazar H_0 si $|t| \geq 3,182$.

Conclusión

Como $|3,65| > 3,182$, **rechazamos la hipótesis nula H_0** con un nivel de significancia del 5 %.

Ejemplo: Intervalo de Confianza para β_1

Calcule un intervalo de confianza del 95 % para el parámetro β_1 .
Como:

$$\hat{\beta}_1 \pm t_{\alpha/2} s \sqrt{c_{11}}$$

Sustituyendo :

$$0,7 \pm (3,182)(0,606)\sqrt{0,1}$$

$$0,7 \pm (3,182)(0,1916)$$

$$0,7 \pm 0,610$$

Intervalo: [0,090, 1,310]

Nota: El intervalo es bastante ancho (casi llega a cero). Si se desea mayor precisión (por ejemplo, una tolerancia de 0.15), es necesario aumentar el tamaño de la muestra n .

Prueba para funciones lineales de los parámetros

Consideramos una función lineal $\theta = a_0\beta_0 + a_1\beta_1$:

Hipótesis: $H_0 : \theta = \theta_0$ vs $H_a : \begin{cases} \theta > \theta_0 \\ \theta < \theta_0 \\ \theta \neq \theta_0 \end{cases}$

Prueba para funciones lineales de los parámetros

Consideramos una función lineal $\theta = a_0\beta_0 + a_1\beta_1$:

Hipótesis: $H_0 : \theta = \theta_0$ vs $H_a : \begin{cases} \theta > \theta_0 \\ \theta < \theta_0 \\ \theta \neq \theta_0 \end{cases}$ **Estadístico de prueba:**

$$T = \frac{\hat{\theta} - \theta_0}{S \sqrt{\frac{a_0^2 \frac{\sum x_i^2}{n} + a_1^2 - 2a_0a_1\bar{x}}{S_{xx}}}}$$

Región de rechazo: Dependiendo de H_a , rechazar si $t > t_{\alpha}$, $t < -t_{\alpha}$ o $|t| > t_{\alpha/2}$, con $n - 2$ grados de libertad.

Intervalo de confianza para $\theta = a_0\beta_0 + a_1\beta_1$

Un intervalo de confianza del $100(1 - \alpha)\%$ para θ es:

Fórmula General

$$\hat{\theta} \pm t_{\alpha/2} S \sqrt{\frac{a_0^2 \frac{\sum x_i^2}{n} + a_1^2 - 2a_0 a_1 \bar{x}}{S_{xx}}}$$

Intervalo de confianza para $\theta = a_0\beta_0 + a_1\beta_1$

Un intervalo de confianza del $100(1 - \alpha)\%$ para θ es:

Fórmula General

$$\hat{\theta} \pm t_{\alpha/2} S \sqrt{\frac{a_0^2 \frac{\sum x_i^2}{n} + a_1^2 - 2a_0a_1\bar{x}}{S_{xx}}}$$

Donde:

- ▶ $\hat{\theta} = a_0\hat{\beta}_0 + a_1\hat{\beta}_1$
- ▶ $t_{\alpha/2}$ se basa en $n - 2$ grados de libertad.
- ▶ Esta fórmula permite evaluar combinaciones de los coeficientes.

Intervalo de Confianza para el valor medio de Y

Un caso particular importante es la estimación de $E(Y)$ cuando $x = x^*$. En este caso $a_0 = 1$ y $a_1 = x^*$, lo que simplifica la fórmula:

Intervalo de confianza para $E(Y) = \beta_0 + \beta_1 x^*$

$$\hat{\beta}_0 + \hat{\beta}_1 x^* \pm t_{\alpha/2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

Intervalo de Confianza para el valor medio de Y

Un caso particular importante es la estimación de $E(Y)$ cuando $x = x^*$. En este caso $a_0 = 1$ y $a_1 = x^*$, lo que simplifica la fórmula:

Intervalo de confianza para $E(Y) = \beta_0 + \beta_1 x^*$

$$\hat{\beta}_0 + \hat{\beta}_1 x^* \pm t_{\alpha/2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

Observación clave:

- ▶ El intervalo es más corto cuando $x^* = \bar{x}$ (en el centro de los datos).
- ▶ Para obtener intervalos más precisos, se requiere un n grande y una dispersión de x (S_{xx}) elevada.

Ejemplo : Estimación de $E(Y)$ para $x = 1$

Para los datos del Ejemplo anterior, determine un intervalo del 90 % para $E(Y)$ cuando $x = 1$.

Datos previos: $n = 5$, $\bar{x} = 0$, $S_{xx} = 10$, $\hat{y} = 1 + 0,7x^*$, $s = 0,606$.

Ejemplo : Estimación de $E(Y)$ para $x = 1$

Para los datos del Ejemplo anterior, determine un intervalo del 90 % para $E(Y)$ cuando $x = 1$.

Datos previos: $n = 5$, $\bar{x} = 0$, $S_{xx} = 10$, $\hat{y} = 1 + 0,7x^*$, $s = 0,606$.

1. $\hat{y} = 1 + 0,7(1) = 1,7$
2. Error estándar de la media:

$$\sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} = \sqrt{\frac{1}{5} + \frac{(1 - 0)^2}{10}} = \sqrt{0,3}$$

3. **Valor crítico ($t_{0,05}$ con 3 g.l.): 2,353**

Cálculo final:

$$1,7 \pm (2,353)(0,606)\sqrt{0,3} \Rightarrow 1,7 \pm 0,781$$

Intervalo: $[0,919, 2,481]$

- ▶ La regresión lineal permite modelar relaciones funcionales simples.
- ▶ El método de mínimos cuadrados es el estándar para estimación.
- ▶ La inferencia estadística nos permite validar si los resultados muestrales son generalizables a la población.

Intervalos de confianza en una muestra grande

Los estimadores puntuales insesgados para los parámetros:

$$\mu, p, \mu_1 - \mu_2 \text{ y } p_1 - p_2$$

Tienen distribuciones muestrales normales con error estándar:

Parámetro objetivo θ	Tamaño(s) muestral(es)	Estimador puntual $\hat{\theta}$	$E(\hat{\theta})$	Error estándar $\sigma_{\hat{\theta}}$
μ	n	$\bar{Y}$	μ	$\frac{\sigma}{\sqrt{n}}$
p	n	$\hat{p} = \frac{Y}{n}$	p	$\sqrt{\frac{pq}{n}}$
$\mu_1 - \mu_2$	n_1 y n_2	$\bar{Y}_1 - \bar{Y}_2$	$\mu_1 - \mu_2$	$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
$p_1 - p_2$	n_1 y n_2	$\hat{p}_1 - \hat{p}_2$	$p_1 - p_2$	$\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}$

σ_1^2 y σ_2^2 son las varianzas de las poblaciones 1 y 2, respectivamente.

† Se supone que las dos muestras son independientes.