

Propiedades de estimadores

Estadística Inferencial

FC-UNI

5 de mayo de 2026

Objetivo

Usar los datos de una muestra para obtener un valor (estimación) que sirva como aproximación de un parámetro desconocido de la población.

Estimador ($\hat{\theta}$): Es una estadística que intenta predecir el valor de algún parámetro de cierta población. Quiere generalizar el resultado obtenido en la muestra para toda la población.

Propiedades

- ▶ Insesgado
- ▶ Eficiente
- ▶ Consistente
- ▶ Suficiente

Estimador eficiente: Dado un estimador insesgado, el estimador **más eficiente** es aquel que tenga la menor varianza.

Estimador consistente:

Un estimador es consistente si, a medida que n aumenta, el valor del estadístico se aproxima al valor del parámetro.

Estimador suficiente:

Un estimador es suficiente si ningún otro estimador puede proporcionar más información sobre el parámetro.

Sesgo y Error Cuadrático Medio

Para evaluar un estimador, primero definimos qué tan lejos está del valor real:

Sesgo

Es la diferencia entre la esperanza del estimador y el parámetro:

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Decimos que un estimador es **insesgado** si $B(\hat{\theta}) = 0$.

Error Cuadrático Medio (ECM)

Mide la calidad total (variabilidad + exactitud):

$$ECM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [B(\hat{\theta})]^2$$

Un buen estimador minimiza ambos componentes.

Error estándar

Sea el estimador $\hat{\theta}$,

La varianza del estimador: $\sigma_{\hat{\theta}}^2$

El **error estándar**: $\sigma_{\hat{\theta}}$

Parámetro θ	Tamaño	Estimador	$E(\hat{\theta})$	Error estándar $\sigma_{\hat{\theta}}$
μ	n	$\bar{X}$	μ	$\frac{\sigma}{\sqrt{n}}$
p	n	$\hat{p} = \frac{\bar{X}}{n}$	p	$\sqrt{\frac{pq}{n}}$
σ^2	n	$\frac{\sum (x_i - \bar{X})^2}{n-1}$	σ^2	$\sigma^2 \sqrt{\frac{2}{n-1}}$
$\mu_1 - \mu_2$	n_1 y n_2	$\bar{X}_1 - \bar{X}_2$	$\mu_1 - \mu_2$	$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
$p_1 - p_2$	n_1 y n_2	$\hat{p}_1 - \hat{p}_2$	$p_1 - p_2$	$\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}$

Propiedades de estimadores puntuales

Eficiencia relativa En general es posible obtener más de un estimador insesgado para el mismo parámetro. Preferimos usar el estimador con la varianza más pequeña.

Definición

Dos estimadores insesgados $\hat{\theta}_1$ y $\hat{\theta}_2$ del parámetro θ , con varianzas $V(\hat{\theta}_1)$ y $V(\hat{\theta}_2)$ respectivamente, la **eficiencia** $\hat{\theta}_1$ respecto $\hat{\theta}_2$:

$$\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)}$$

- ▶ Si $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) > 1$, significa que $V(\hat{\theta}_2) > V(\hat{\theta}_1)$, por lo que $\hat{\theta}_1$ es **más eficiente**
- ▶ Si $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) < 1$, entonces $\hat{\theta}_2$ es preferible.

Cota Inferior de Cramer-Rao (CICR)

¿Existe un límite para qué tan pequeña puede ser la varianza de un estimador insesgado? **Sí.**

Teorema

Bajo condiciones de regularidad, para cualquier estimador insesgado $\hat{\theta}$ de θ :

$$V(\hat{\theta}) \geq \frac{1}{nI(\theta)}$$

donde $I(\theta)$ es la **Información de Fisher**: $I(\theta) = -E \left[\frac{\partial^2 \ln f(Y|\theta)}{\partial \theta^2} \right]$.

Implicaciones:

- ▶ Si un estimador alcanza esta cota, se dice que es **eficiente**.
- ▶ Nos da un estándar para evaluar si nuestro estimador es el "mejor" posible en términos de precisión.

Ejemplo:

Sea $Y_1, Y_2, \dots, Y_n$ una muestra aleatoria de una distribución uniforme en $(0, \theta)$. Dos estimadores insesgados para θ son:

$$\hat{\theta}_1 = 2\bar{Y} \quad \text{y} \quad \hat{\theta}_2 = \left(\frac{n+1}{n}\right) Y_{(n)}$$

donde $Y_{(n)} = \max(Y_1, Y_2, \dots, Y_n)$. Encuentre la eficiencia de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$.

Solución:

Varianza de $\hat{\theta}_1$: $\mu = E(Y_i) = \theta/2$ pues Y_i tiene distribución uniforme en $(0, \theta)$ y $\sigma^2 = V(Y_i) = \theta^2/12$. Por tanto

$$E(\hat{\theta}_1) = 2E(\bar{Y}) = 2(\theta/2) = \theta \quad (\text{insesgado})$$

$$V(\hat{\theta}_1) = V(2\bar{Y}) = 4V(\bar{Y}) = 4 \left[\frac{V(Y_i)}{n} \right] = 4 \left(\frac{\theta^2}{12n} \right) = \frac{\theta^2}{3n}.$$

Ejemplo: Varianza de $\hat{\theta}_2$

Varianza de $\hat{\theta}_2$

La función de densidad del máximo $Y_{(n)}$ es:

$$g_{(n)}(y) = n[F_Y(y)]^{n-1}f_Y(y) = n\left(\frac{y}{\theta}\right)^{n-1}\left(\frac{1}{\theta}\right), \quad 0 \leq y \leq \theta.$$

Calculamos los momentos:

$$E(Y_{(n)}) = \frac{n}{\theta^n} \int_0^\theta y^n dy = \left(\frac{n}{n+1}\right)\theta$$

$$E(Y_{(n)}^2) = \frac{n}{\theta^n} \int_0^\theta y^{n+1} dy = \left(\frac{n}{n+2}\right)\theta^2$$

La varianza de $Y_{(n)}$ es:

$$V(Y_{(n)}) = E(Y_{(n)}^2) - [E(Y_{(n)})]^2 = \left[\frac{n}{n+2} - \left(\frac{n}{n+1}\right)^2\right]\theta^2$$

Ejemplo: Conclusión de eficiencia

Sustituyendo para hallar $V(\hat{\theta}_2)$:

$$\begin{aligned} V(\hat{\theta}_2) &= V \left[\left(\frac{n+1}{n} \right) Y_{(n)} \right] = \left(\frac{n+1}{n} \right)^2 V(Y_{(n)}) \\ &= \left[\frac{(n+1)^2}{n(n+2)} - 1 \right] \theta^2 = \frac{\theta^2}{n(n+2)}. \end{aligned}$$

Por tanto, la eficiencia de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$ está dada por:

$$\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)} = \frac{\frac{\theta^2}{n(n+2)}}{\frac{\theta^2}{3n}} = \frac{3}{n+2}.$$

Esta eficiencia es menor que 1 si $n > 1$. Es decir, para $n > 1$, $\hat{\theta}_2$ (basado en el máximo) tiene menor varianza que $\hat{\theta}_1$ (basado en la media) y, por tanto, **se prefiere** $\hat{\theta}_2$.

Definición

Se dice que el estimador $\hat{\theta}_n$ es un **estimador consistente** de θ si, para cualquier número positivo ε ,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \leq \varepsilon) = 1$$

o bien, de forma equivalente,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0.$$

La notación $\hat{\theta}_n$ expresa que el estimador se calcula usando una muestra de tamaño n . Decir que $\hat{\theta}_n$ es consistente equivale a decir que " **$\hat{\theta}_n$ converge en probabilidad en θ** ".

Teorema: Consistencia vía Varianza

Si $\hat{\theta}_n$ es un estimador insesgado, el siguiente teorema facilita demostrar su consistencia.

Teorema

Un estimador insesgado $\hat{\theta}_n$ para θ es un estimador consistente de θ si

$$\lim_{n \rightarrow \infty} V(\hat{\theta}_n) = 0.$$

Demostración (Inicio): Por el teorema de Tchebysheff para cualquier variable Y con $E(Y) = \mu$ y $V(Y) = \sigma^2$:

$$P(|Y - \mu| > k\sigma) \leq \frac{1}{k^2}$$

Aplicando esto al estimador insesgado $\hat{\theta}_n$ (donde $E(\hat{\theta}_n) = \theta$ y $\sigma_{\hat{\theta}_n} = \sqrt{V(\hat{\theta}_n)}$):

$$P(|\hat{\theta}_n - \theta| > k\sigma_{\hat{\theta}_n}) \leq \frac{1}{k^2}.$$

Demostración (Continuación)

Sea n fijo. Para cualquier número positivo ε , elegimos $k = \frac{\varepsilon}{\sigma_{\hat{\theta}_n}}$.

Sustituyendo en Tchebysheff:

$$P(|\hat{\theta}_n - \theta| > \varepsilon) = P\left(|\hat{\theta}_n - \theta| > \left\lceil \frac{\varepsilon}{\sigma_{\hat{\theta}_n}} \right\rceil \sigma_{\hat{\theta}_n}\right) \leq \frac{1}{(\varepsilon/\sigma_{\hat{\theta}_n})^2} = \frac{V(\hat{\theta}_n)}{\varepsilon^2}$$

Entonces, acotamos la probabilidad:

$$0 \leq P(|\hat{\theta}_n - \theta| > \varepsilon) \leq \frac{V(\hat{\theta}_n)}{\varepsilon^2}.$$

Si $\lim_{n \rightarrow \infty} V(\hat{\theta}_n) = 0$, tomamos el límite en la desigualdad:

$$\lim_{n \rightarrow \infty} (0) \leq \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) \leq \lim_{n \rightarrow \infty} \frac{V(\hat{\theta}_n)}{\varepsilon^2} = 0.$$

Por el teorema del sándwich, el límite central es 0. Entonces, $\hat{\theta}_n$ es consistente.

Ley de los grandes números

EJEMPLO Sea $Y_1, Y_2, \dots, Y_n$ una muestra aleatoria de una distribución con media μ y varianza $\sigma^2 < \infty$. Demuestre que $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$ es un estimador consistente de μ .

Solución

Sabemos que $E(\bar{Y}_n) = \mu$ y $V(\bar{Y}_n) = \sigma^2/n$.

Como $\bar{Y}_n$ es insesgado para μ y $\lim_{n \rightarrow \infty} V(\bar{Y}_n) = \lim_{n \rightarrow \infty} \frac{\sigma^2}{n} = 0$, el Teorema 9.1 establece que $\bar{Y}_n$ es un estimador consistente de μ .

Nota: Al hecho de que $\bar{Y}_n$ sea consistente para μ (o converja en probabilidad en μ), se le conoce como la **ley de los grandes números**. Ésta justifica el proceso de promediar muchas observaciones para obtener alta precisión.

Ejemplo

Demostrar que $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y}_n)^2$ es un estimador consistente de σ^2 .

Esquema de la demostración:

1. Reescritura: $S_n^2 = \left(\frac{n}{n-1}\right) \left[\frac{1}{n} \sum Y_i^2 - \bar{Y}_n^2\right]$.
2. Por la **Ley de los Grandes Números**:
 - ▶ $\frac{1}{n} \sum Y_i^2 \xrightarrow{P} E(Y^2) = \mu'_2$
 - ▶ $\bar{Y}_n \xrightarrow{P} \mu \implies \bar{Y}_n^2 \xrightarrow{P} \mu^2$
3. Entonces: $\left(\frac{1}{n} \sum Y_i^2 - \bar{Y}_n^2\right) \xrightarrow{P} \mu'_2 - \mu^2 = \sigma^2$.
4. Como $\lim_{n \rightarrow \infty} \frac{n}{n-1} = 1$, concluimos que:

$$S_n^2 \xrightarrow{P} \sigma^2$$

Estadísticos Suficientes: Concepto

Un estadístico es suficiente si agota toda la información sobre θ presente en la muestra.

Definición

$U = g(Y_1, \dots, Y_n)$ es **suficiente** para θ si la distribución condicional de la muestra, dado U , no depende de θ .

Definición : La Verosimilitud $L(\theta)$

Es la distribución conjunta de la muestra vista como función de θ :

- ▶ **Caso discreto:** $L(\theta) = p(y_1, y_2, \dots, y_n | \theta)$
- ▶ **Caso continuo:** $L(\theta) = f(y_1, y_2, \dots, y_n | \theta)$

Para muestras i.i.d.: $L(\theta) = f(y_1 | \theta) \times f(y_2 | \theta) \times \dots \times f(y_n | \theta)$

Para hallar estadísticos suficientes sin usar distribuciones condicionales complejas, usamos:

Teorema

U es suficiente para θ si y sólo si la verosimilitud se puede factorizar como:

$$L(y_1, y_2, \dots, y_n | \theta) = g(u, \theta) \times h(y_1, y_2, \dots, y_n)$$

Condiciones:

- ▶ $g(u, \theta)$ es función únicamente de u y θ .
- ▶ $h(y_1, \dots, y_n)$ no depende de θ .

Ejemplo Distribución Exponencial

Sea $f(y_i|\theta) = \frac{1}{\theta}e^{-y_i/\theta}$ para $y_i \geq 0$. Demostrar que $\bar{Y}$ es suficiente.

1. Hallar la Verosimilitud:

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-y_i/\theta} = \frac{1}{\theta^n} e^{-\sum y_i/\theta} = \frac{1}{\theta^n} e^{-n\bar{y}/\theta}$$

2. Identificar factores:

- ▶ $g(\bar{y}, \theta) = \frac{1}{\theta^n} e^{-n\bar{y}/\theta}$ (depende de θ y del estadístico $\bar{y}$)
- ▶ $h(y_1, \dots, y_n) = 1$ (no depende de θ)

Conclusión

Como se cumple la factorización, por el Teorema la media muestral $\bar{Y}$ es un **estadístico suficiente** para el parámetro θ .

Semana 7: Teorema de Rao-Blackwell

Este teorema permite mejorar un estimador insesgado utilizando la información de un estadístico suficiente.

Teorema

Sea $\hat{\theta}$ un estimador insesgado para θ con $V(\hat{\theta}) < \infty$. Si U es un estadístico suficiente para θ , definamos $\hat{\theta}^* = E(\hat{\theta}|U)$. Entonces, para toda θ :

1. $E(\hat{\theta}^*) = \theta$ (**Insesgado**)
2. $V(\hat{\theta}^*) \leq V(\hat{\theta})$ (**Varianza menor o igual**)

Idea clave: Si queremos reducir la varianza, debemos buscar estimadores que sean funciones de estadísticos suficientes.

¿Por qué funciona Rao-Blackwell?

La demostración se basa en propiedades de la esperanza y varianza condicional:

- ▶ **Insesgadez:** Por la ley de esperanza total:

$$E(\hat{\theta}^*) = E[E(\hat{\theta}|U)] = E(\hat{\theta}) = \theta$$

- ▶ **Varianza:** Por la ley de varianza total:

$$V(\hat{\theta}) = V[E(\hat{\theta}|U)] + E[V(\hat{\theta}|U)] = V(\hat{\theta}^*) + E[V(\hat{\theta}|U)]$$

- ▶ Como $V(\hat{\theta}|U) \geq 0$, se deduce que:

$$V(\hat{\theta}) \geq V(\hat{\theta}^*)$$

Nota: $\hat{\theta}^$ es un estadístico porque, al ser U suficiente, la distribución condicional (y su esperanza) no depende de θ .*

Estimador Insesgado de Varianza Mínima (MVUE)

El proceso de Rao-Blackwell nos lleva hacia el "mejor" estimador posible.

MVUE (Minimum Variance Unbiased Estimator)

Es un estimador insesgado que tiene la varianza menor posible entre todos los estimadores insesgados para un parámetro θ .

Estrategia para hallar un MVUE:

1. Encontrar un estadístico suficiente U (usando el criterio de factorización).
2. Encontrar una función de dicho estadístico, $h(U)$, que sea insesgada para θ .
3. Si el estadístico es suficiente y "completo", entonces $\hat{\theta} = h(U)$ es el MVUE.

Estrategia para hallar un MVUE único

El proceso de Rao-Blackwell nos da un camino, pero el siguiente teorema garantiza la unicidad:

Teorema de Lehmann-Scheffé

Si U es un estadístico **suficiente y completo** para θ , y si $\hat{\theta}^* = h(U)$ es un estimador tal que $E(\hat{\theta}^*) = \theta$, entonces:

$\hat{\theta}^*$ es el **único MVUE** de θ .

Pasos actualizados:

1. Hallar un estadístico suficiente U (Criterio de Factorización).
2. Verificar o buscar una función $h(U)$ que sea insesgada.
3. Por Lehmann-Scheffé, esta función es el mejor estimador posible.

Ejemplo: MVUE para una Bernoulli

Sea $Y_1, \dots, Y_n$ una muestra de una distribución Bernoulli con parámetro p .

1. **Verosimilitud:** $L(p) = \prod p^{y_i}(1-p)^{1-y_i} = p^{\sum y_i}(1-p)^{n-\sum y_i}$.
2. **Suficiencia:** Por factorización, $U = \sum_{i=1}^n Y_i$ es suficiente para p .
3. **Insesgadez:** Sabemos que $E(U) = np$, por lo tanto:

$$E\left(\frac{U}{n}\right) = E(\bar{Y}) = p$$

Conclusión

Como $\bar{Y}$ es una función del estadístico suficiente $\sum Y_i$ y es insesgado para p , entonces $\hat{p} = \bar{Y}$ es el **MVUE** para p .

Ejemplo : MVUE en Distribución Weibull

Sea $f(y|\theta) = \frac{2y}{\theta} e^{-y^2/\theta}$ para $y > 0$. Buscamos el MVUE para θ .

1. **Suficiencia:** Factorizando la verosimilitud:

$$L(\theta) = \left(\frac{2}{\theta}\right)^n \left(\prod y_i\right) \exp\left(-\frac{1}{\theta} \sum y_i^2\right)$$

Se deduce que $U = \sum Y_i^2$ es el estadístico suficiente.

2. **Insensgadez:** Sea $W = Y^2$. Mediante transformación de variables, se demuestra que $W \sim \text{Exp}(\theta)$.
3. **Cálculo:** Como $E(Y_i^2) = \theta$, entonces $E(\sum Y_i^2) = n\theta$.

Resultado

El estimador $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n Y_i^2$ es el **MVUE** para θ .

Ejemplo : MVUE en la Distribución Normal

En una $N(\mu, \sigma^2)$, con ambos parámetros desconocidos:

- ▶ **Suficiencia Conjunta:** Al expandir la verosimilitud, se observa que $(\sum Y_i, \sum Y_i^2)$ son estadísticos suficientes conjuntos.
- ▶ **Estimadores conocidos:** $\bar{Y}$ y S^2 son funciones de estos estadísticos suficientes.
- ▶ **Propiedad:** Como $\bar{Y}$ es insesgado para μ y S^2 es insesgado para σ^2 :

Nota

$\bar{Y}$ es el **MVUE** para μ y S^2 es el **MVUE** para σ^2 .

Ejemplo: MVUE para funciones de parámetros

En una distribución Exponencial, queremos hallar el MVUE para la varianza $V(Y) = \theta^2$.

- ▶ Sabemos que $\bar{Y}$ es el MVUE de θ . Podríamos pensar en $\bar{Y}^2$, pero:

$$E(\bar{Y}^2) = V(\bar{Y}) + [E(\bar{Y})]^2 = \frac{\theta^2}{n} + \theta^2 = \left(\frac{n+1}{n}\right) \theta^2$$

- ▶ El estimador $\bar{Y}^2$ es **sesgado**.

Ajuste por insesgadez

Para obtener el MVUE, corregimos el factor de sesgo:

$$\hat{\theta}^2 = \left(\frac{n}{n+1}\right) \bar{Y}^2$$

Uso de Estadísticos Suficientes en Intervalos

Los estadísticos suficientes también sirven para construir **cantidades pivote** precisas.

Ejemplo (Weibull)

Para la Weibull del ejemplo anterior, definimos $T_i = \frac{2Y_i^2}{\theta} \sim \chi^2(2)$.
Para una muestra de $n = 10$:

$$\sum T_i = \frac{2}{\theta} \sum Y_i^2 \sim \chi^2(20)$$

Intervalo de confianza del 95 %: Usando los cuantiles $a = 9,591$ y $b = 34,170$ de la tabla χ^2 :

$$P\left(a \leq \frac{2 \sum Y_i^2}{\theta} \leq b\right) = 0,95 \implies \left[\frac{2 \sum Y_i^2}{b}, \frac{2 \sum Y_i^2}{a}\right]$$

Para los datos del ejemplo, el intervalo resulta en (1,442, 5,139).

Resumen: para hallar un MVUE

A partir de lo visto en esta sección (Teorema de Rao-Blackwell), el procedimiento estándar para encontrar el mejor estimador posible es:

1. **Identificar suficiencia:** Aplicar el criterio de factorización para hallar el estadístico suficiente U .
2. **Garantizar insesgadez:** Buscar una función $h(U)$ tal que:

$$E[h(U)] = \theta$$

Limitaciones del método

A veces, el estadístico suficiente U es una función muy compleja de la muestra, lo que dificulta encontrar la función $h(U)$ exacta que sea insesgada.

**** Repaso: Métodos de Estimación****

Cuando el camino de la suficiencia y Rao-Blackwell es difícil de transitar, se recurre a métodos alternativos para construir estimadores:

- ▶ **Método de los Momentos:** Basado en igualar momentos muestrales con momentos poblacionales.
- ▶ **Método de Máxima Verosimilitud (MLE):** Basado en maximizar la probabilidad de observar la muestra actual (será el tema de la siguiente sección).
- ▶ **Mínimos Cuadrados:** Fundamental en modelos de regresión

1. Método de los Momentos (MOM)

Consiste en igualar los momentos poblacionales $\mu'_k = E(Y^k)$ con los momentos muestrales $m_k = \frac{1}{n} \sum Y_i^k$.

Procedimiento

Se resuelve un sistema de ecuaciones: $\mu'_k(\theta_1, \dots, \theta_m) = m_k$ para hallar los estimadores.

Ejemplo: Distribución Uniforme $(0, \theta)$

1. Momento poblacional: $E(Y) = \frac{\theta}{2}$.
2. Momento muestral: $m_1 = \bar{Y}$.
3. Igualamos: $\frac{\hat{\theta}}{2} = \bar{Y} \implies \hat{\theta}_{\text{MOM}} = 2\bar{Y}$.

Ventaja: Muy sencillo de calcular. Desventaja: No siempre produce estimadores eficientes.

2. Máxima Verosimilitud (MLE)

Busca el valor del parámetro $\hat{\theta}$ que maximiza la probabilidad de haber observado la muestra actual. Es el método más utilizado en estadística moderna.

Procedimiento

1. Escribir la verosimilitud $L(\theta)$. 2. Aplicar logaritmo: $\ln L(\theta)$ (facilita derivadas). 3. Derivar e igualar a cero: $\frac{d}{d\theta} \ln L(\theta) = 0$.

Ejemplo: Distribución Poisson (λ)

$$L(\lambda) = \frac{e^{-n\lambda} \lambda^{\sum y_i}}{\prod y_i!} \implies \ln L(\lambda) = -n\lambda + (\sum y_i) \ln \lambda - \ln(\prod y_i!)$$

$$\text{Derivando respecto a } \lambda: -n + \frac{\sum y_i}{\lambda} = 0 \implies \hat{\lambda}_{\text{MLE}} = \bar{Y}.$$

Propiedades de los Estimadores de Máxima Verosimilitud

Los estimadores $\hat{\theta}_{MLE}$ son los más usados por sus propiedades:

- ▶ **Invarianza:** Si $\hat{\theta}$ es el MLE de θ , el MLE de $g(\theta)$ es $g(\hat{\theta})$. (Ej: El MLE de σ^2 es simplemente $\hat{\sigma}^2$).
- ▶ **Consistencia:** Bajo condiciones generales, $\hat{\theta}_{MLE} \xrightarrow{P} \theta$.
- ▶ **Eficiencia Asintótica:** Para n grande, su varianza alcanza la Cota de Cramer-Rao.
- ▶ **Normalidad Asintótica:** Para n grande:

$$\hat{\theta}_{MLE} \approx N\left(\theta, \frac{1}{nI(\theta)}\right)$$

3. Método de Mínimos Cuadrados (LSE)

Se utiliza principalmente para modelar relaciones entre variables. El objetivo es minimizar la suma de los cuadrados de los errores (residuos).

Criterio

Minimizar $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$, donde $\hat{y}_i$ es el valor predicho por el modelo.

Ejemplo: Regresión Lineal Simple

Modelo: $Y = \beta_0 + \beta_1 x + \epsilon$. Buscamos $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la distancia vertical de los puntos a la recta:

$$SSE = \sum [y_i - (\beta_0 + \beta_1 x_i)]^2$$

Nota: No requiere suponer una distribución específica para los datos (es robusto"), a diferencia del MLE.

Resumen Comparativo de Métodos

Método	Fundamento	Uso principal
Momentos	Igualdad de promedios.	Estimaciones rápidas y simples.
MLE	Máx probabilidad conjunta.	Inferencia óptima (asintótica).
Mí. Cua	Mínimo error de predicción.	Modelos de regresión y ajuste.

Dato

En la **Distribución Normal**, los tres métodos coinciden: el estimador de la media μ es siempre $\bar{Y}$ por cualquiera de las tres vías.

Apéndice I: Álgebra de Momentos

1. Propiedades de la Esperanza (E)

- ▶ $E(cX + d) = cE(X) + d$
- ▶ $E(X \pm Y) = E(X) \pm E(Y)$
- ▶ $E(XY) = E(X)E(Y)$ (Si X, Y son independientes)

2. Propiedades de la Varianza (V)

- ▶ $V(cX + d) = c^2 V(X)$
- ▶ $V(X \pm Y) = V(X) + V(Y)$ (Si X, Y son independientes)
- ▶ **Fórmula fundamental:** $V(X) = E(X^2) - [E(X)]^2$

3. Momentos y Muestras

- ▶ Media muestral: $E(\bar{Y}) = \mu$
- ▶ Varianza de la media: $V(\bar{Y}) = \sigma^2/n$
- ▶ Sumatorias: $\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum Y_i^2 - n\bar{Y}^2$

Apéndice II: Herramientas de Inferencia

1. Esperanza y Varianza Condicional (Rao-Blackwell)

- ▶ **Ley de Esperanza Total:** $E(X) = E[E(X|Y)]$
- ▶ **Ley de Varianza Total:** $V(X) = E[V(X|Y)] + V[E(X|Y)]$

2. Convergencia y Límites (Consistencia)

- ▶ **En Probabilidad ($\xrightarrow{P}$):** $\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \epsilon) = 0$. Define la consistencia.
- ▶ **Ley de los Grandes Números:** $\bar{Y}_n \xrightarrow{P} \mu$ cuando $n \rightarrow \infty$.
- ▶ **En Distribución ($\xrightarrow{d}$):** La forma de la distribución se aproxima a una conocida (ej. Normal).
- ▶ **Desigualdad de Tchebysheff:** $P(|X - \mu| \geq k\sigma) \leq 1/k^2$.

Apéndice III: Distribuciones: Discretas

- ▶ **Bernoulli (p):** Un solo ensayo (éxito/fracaso).
 - ▶ $E(Y) = p, V(Y) = p(1 - p)$
 - ▶ **Suficiencia:** $\sum Y_i$ — **MVUE:** $\hat{p} = \bar{Y}$
- ▶ **Binomial (n, p):** n ensayos independientes.
 - ▶ $E(Y) = np, V(Y) = np(1 - p)$
 - ▶ **Suficiencia:** $\sum Y_i$ — **MVUE:** $\hat{p} = \bar{Y}/n$
- ▶ **Poisson (λ):** Conteos en un intervalo.
 - ▶ $E(Y) = \lambda, V(Y) = \lambda$
 - ▶ **Suficiencia:** $\sum Y_i$ — **MVUE:** $\hat{\lambda} = \bar{Y}$

Nota: En estas distribuciones (familia exponencial), la suma de los datos suele ser el estadístico suficiente.

Apéndice III: Distribuciones: Continuas (I)

- ▶ **Exponencial (θ):** Tiempo entre eventos.
 - ▶ $E(Y) = \theta, V(Y) = \theta^2$
 - ▶ **Suficiencia:** $\sum Y_i$ — **MVUE:** $\hat{\theta} = \bar{Y}$
 - ▶ **Nota:** Para θ^2 , el MVUE es $\left(\frac{n}{n+1}\right) \bar{Y}^2$.
- ▶ **Gamma (α, β):** (Con α conocido).
 - ▶ $E(Y) = \alpha\beta, V(Y) = \alpha\beta^2$
 - ▶ **Suficiencia:** $\sum Y_i$ — **MVUE de β :** $\hat{\beta} = \bar{Y}/\alpha$
- ▶ **Normal (μ, σ^2):**
 - ▶ **Estandarización:** $Z = (X - \mu)/\sigma \sim N(0, 1)$.
 - ▶ **Suficiencia Conjunta:** $(\sum Y_i, \sum Y_i^2)$.
 - ▶ **MVUEs:** $\hat{\mu} = \bar{Y}$ y $\hat{\sigma}^2 = S^2 = \frac{\sum (Y_i - \bar{Y})^2}{n-1}$.

Apéndice III Casos Especiales

- ▶ **Weibull (θ):** (Según Ejemplo 9.7)
 - ▶ Propiedad clave: $Y^2 \sim \text{Exp}(\theta)$.
 - ▶ **Suficiencia:** $\sum Y_i^2$ — **MVUE:** $\hat{\theta} = \frac{1}{n} \sum Y_i^2$
- ▶ **Uniforme ($0, \theta$):** Parámetro en el soporte.
 - ▶ $f(y|\theta) = 1/\theta, \quad 0 \leq y \leq \theta$
 - ▶ **Suficiencia:** $Y_{(n)} = \max(Y_1, \dots, Y_n)$.
 - ▶ **MVUE:** $\hat{\theta} = \left(\frac{n+1}{n}\right) Y_{(n)}$

Importante

La **Uniforme** es el caso típico donde el estadístico suficiente NO es una suma, sino un valor extremo (el máximo), porque el parámetro define el límite de los datos observables.

Apéndice IV: Estandarizaciones y Cantidades Pivote

- ▶ **Caso Normal** $N(\mu, \sigma^2)$:

$$Z = \frac{Y - \mu}{\sigma} \sim N(0, 1) \quad | \quad Z^2 \sim \chi^2(1)$$

- ▶ **Aproximaciones (Teorema del Límite Central)**: Para n grande, estandarizamos usando la media y error estándar:

- ▶ **Binomial**: $Z = \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \approx N(0, 1)$

- ▶ **Poisson**: $Z = \frac{\bar{Y} - \lambda}{\sqrt{\lambda/n}} \approx N(0, 1)$

- ▶ **Transformaciones Especiales (Cantidades Pivote)**: Vistas en los ejemplos del texto para construir intervalos:

- ▶ **Exponencial**: Si $Y \sim \text{Exp}(\theta) \implies \frac{2Y}{\theta} \sim \chi^2(2)$

- ▶ **Weibull**: Si $f(y|\theta) = \frac{2y}{\theta} e^{-y^2/\theta} \implies \frac{2Y^2}{\theta} \sim \chi^2(2)$

NOta

Una vez estandarizada (o pivotada), la distribución ya no depende de los parámetros desconocidos, permitiendo usar tablas (χ^2 , Z , t) para inferencia.

Resumen General de Parámetros y MVUE

Distribución	Estandarización / Pivote	Est. Suficiente	MVUE
Normal (μ)	$Z = (Y - \mu)/\sigma$	$\sum Y_i$	$\bar{Y}$
Normal (σ^2)	$(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$	$\sum (Y_i - \bar{Y})^2$	S^2
Binomial (p)	$Z \approx (\hat{p} - p)/SE$	$\sum Y_i$	$\bar{Y}/n$
Exponencial (θ)	$2 \sum Y_i/\theta \sim \chi^2(2n)$	$\sum Y_i$	$\bar{Y}$
Poisson (λ)	$Z \approx (\bar{Y} - \lambda)/SE$	$\sum Y_i$	$\bar{Y}$
Uniforme (θ)	$Y_{(n)}/\theta \sim \text{Beta}(n, 1)$	$Y_{(n)}$	$\frac{n+1}{n} Y_{(n)}$